

DRAFT SPESIFIKASI TEKNIS SISTEM PENILAIAN & ALGORITMA METRIK SOFTWARE TUTURAI

Platform Adaptive Speaking Learning Berbasis Hybrid Edge-Cloud AI untuk Mengurangi Speaking Anxiety (LIDM 2026)

Dokumen ID:	TUTURAI-SPECS-2026-V2.4	Tanggal Revisi:	September 2026
Tim Pengembang:	M. Yusuf Aditiya, Rafi R., Dimas R., Rahadian M.I. (ITERA)	Status:	PRODUCTION READY (APPROVED)

BAB 1: FILOSOFI & PRINSIP UTAMA PENILAIAN TUTURAI

Sistem penilaian TutarAI dikembangkan untuk memecahkan kelemahan utama platform komersial Barat (seperti ELSA Speak dan Duolingo) yang sering memberikan hukuman penalti skor terlalu tinggi pada siswa Indonesia akibat perbedaan aksen lokal. TutarAI mengadopsi prinsip **Intelligibility over Accent Calibration** dan menyelaraskan evaluasi dengan standar **Common European Framework of Reference for Languages (CEFR)**.

1.1 Kalibrasi Aksen Asia Tenggara & Indonesia

Dalam domain *Second Language Acquisition (SLA)*, memiliki aksen lokal (*accentedness*) tidak sama dengan ketidakpahaman (*unintelligibility*). TutarAI memanfaatkan model akustik indonesian-nlp/wav2vec2-indonesian-javanese-sundanese yang di-fine-tune menggunakan dataset **Common Voice Indonesian** untuk mengenali variabilitas wicara khas siswa SMA/SMK Indonesia (seperti pengaruh dialek Jawa, Sunda, Sumatera, dll.). Pembelajar dinilai berdasarkan **apakah pesan lisan dapat dipahami secara jelas**, bukan dipaksa menirukan aksen *native speaker* Amerika atau Inggris.

1.2 Kerangka Kerja Standar CEFR (Common European Framework)

Seluruh metrik kuantitatif pada TutarAI dikonversikan secara otomatis ke tingkatan kompetensi CEFR (A1 = Beginner, A2 = Elementary, B1 = Intermediate, B2 = Upper Intermediate). Hal ini memastikan bahwa hasil evaluasi berbasis AI dapat dipertanggungjawabkan secara akademis dan mudah dipahami oleh guru dalam laporan *Teacher Dashboard*.

BAB 2: FORMULASI MATEMATIS 5 DIMENSI PENILAIAN (WEIGHTED SCORING SYSTEM)

TutarAI mengintegrasikan 5 dimensi penilaian berbicara secara simultan. Setiap kali siswa menyelesaikan sesi wicara, sistem menghitung skor \$0-100\$ pada tiap dimensi sebelum digabungkan menjadi Skor Akhir (\$S_{final}\$).

Persamaan Agregasi Skor Akhir (Weighted Scoring):

$$S_{final} = 0.25 S_p + 0.20 S_f + 0.15 S_i + 0.20 S_g + 0.20 S_v$$

Dimensi	Bobot	Metrik Utama	Model AI Engine	Deskripsi Penilaian
Pronunciation (S_p)	25%	Phoneme Error Rate (PER)	Wav2Vec2 / TinyML	Akurasi artikulasi fonem dengan toleransi aksen lokal.
Fluency (S_f)	20%	WPM & Pause Duration Ratio	Qwen3-ASR Temporal	Kelancaran dan ritme bicara berbasis baseline Asia Tenggara.
Intonation (S_i)	15%	Pitch Contour (F_0) & Stress	DSP Pitch Extractor	Variasi nada dan penekanan suku kata yang wajar.
Grammar (S_g)	20%	Grammatical Error Density	Gemma 4 E4B Instruct	Ketepatan struktur kalimat dan tenses berstandar CEFR.
Vocabulary (S_v)	20%	Type-Token Ratio (TTR)	Gemma 4 / CEFR Dict	Kekayaan variasi kosakata dan kecocokan konteks.

2.2 Formulasi Eksak & Aturan Kalibrasi Tiap Dimensi

A. Pronunciation Score (S_p) — Bobot 25%:

Dihitung berdasarkan *Phoneme Error Rate (PER)* hasil ekstraksi akustik. Rumus PER: $PER = (S + D + I) / N$ (S = Substitusi, D = Delesi, I = Inseri, N = Total Fonem Target).

$$S_p = 100 \times (1 - PER_{\text{calibrated}})$$

Aturan Kalibrasi Aksen: Pengucapan fonem khas Indonesia (seperti kata 'think' diucapkan /t■■■k/ alih-alih /θ■■■k/) hanya diberikan penalti ringan (10-15%), tidak dinilai nol (0) karena makna kata tetap dapat dipahami (*intelligible*).

B. Fluency Score (S_f) — Bobot 20%:

Menggabungkan laju bicara (Words Per Minute) dan rasio durasi jeda/hening (Pause Ratio). Target laju bicara dikalibrasi untuk pembelajar EFL Asia Tenggara (**70 - 110 WPM**), berbeda dengan penutur asli (130 - 160 WPM).

$$S_f = [0.6 \times WPM_{\text{norm}} + 0.4 \times (1 - R_{\text{pause}})] \times 100$$

C. Intonation Score (S_i) — Bobot 15%:

Mengevaluasi kontur frekuensi dasar (F_0). Menghindari hukuman pada intonasi datar khas bahasa daerah Jawa/Sunda, tetapi mengukur tren kenaikan variasi pitch secara bernilai positif.

D. Grammar Score (S_g) — Bobot 20%:

Dianalisis oleh Small Language Model Gemma 4 Instruct menggunakan penalti bertingkat berbasis bobot kesalahan:

$$S_g = \max(0, 100 - \sum (\text{Jumlah Kesalahan} \times \text{Bobot Penalti}))$$

- Kesalahan Ringan (penulisan artikel a/an): Penalti -5 | Sedang (Subject-Verb Agreement): Penalti -10 | Berat (Tenses salah pada konteks): Penalti -15.

E. Vocabulary Score (S_v) — Bobot 20%:

Mengevaluasi keanekaragaman kata menggunakan *Type-Token Ratio (TTR)* dipadukan dengan tingkat CEFR kosakata:

$$TTR = (\text{Jumlah Kata Unik}) / (\text{Total Kata Diproduksi})$$

$$S_v = [0.5 \times TTR_{\text{norm}} + 0.5 \times \text{Skor_CEFR_Vocab}] \times 100$$

BAB 3: KOMPONEN TEKNIS & LOGIKA INTEGRASI SOFTWARE (PRODUCTION-READY)

Agar sistem penilaian dapat diimplementasikan ke dalam kode program (FastAPI Backend, ESP32-S3 Firmware, dan PWA Frontend) secara tangguh tanpa kendala di lapangan, 5 komponen logikal berikut diterapkan:

3.1 Logika Penilaian Mode Ganda (Dual-Mode Fallback Logic)

Perangkat ESP32-S3 memiliki keterbatasan memori sehingga tidak dapat mengeksekusi model NLP berat secara offline. Sistem menggunakan dual-mode scoring:

- Mode Offline (Edge Device Scoring):** ESP32-S3 mengeksekusi TinyML & DSP lokal untuk menghitung $S_{p_offline}$ dan $S_{f_offline}$. Skor sementara ditampilkan di LCD dengan formula: $\text{Skor_Offline} = 0.70 S_{p_offline} + 0.30 S_{f_offline}$.
- Mode Online (Cloud Reprocessing):** Saat terhubung internet, file audio `.wav` diunggah ke FastAPI backend. Model Wav2Vec2, Qwen3-ASR, dan Gemma 4 mengeksekusi ulang penilaian penuh 5 dimensi dan menimpa (*override*) skor sementara di database Supabase.

3.2 Gatekeeper Kualitas Audio (Audio SNR Filter / Q_{audio})

Mencegah kegagalan AI akibat derau kelas bising atau rekaman terlalu pendek yang dapat memicu kecemasan siswa. Sistem memeriksa *Signal-to-Noise Ratio (SNR)* dan durasi wicara:

- Jika **SNR < 10 dB** ATAU **Durasi Wicara < 1.5 detik**: AI menolak memproses skor dan mengembalikan status `RETRY_AUDIO_TOO_NOISY` atau `RETRY_SPEECH_TOO_SHORT`.
- Antarmuka menampilkan pesan psikologis ramah: *'Suara kurang jelas/terlalu bising. Yuk, coba bicara sedikit lebih keras!'* demi menjaga *Safe Speaking Environment*.

3.3 Boundary Rules & Mathematical Clamping

Mencegah kesalahan kalkulasi (pembagian dengan nol atau skor melampaui 100) dalam kode Python/C++:

$$\begin{aligned} WPM_{\text{norm}} &= \text{clamp}((WPM - 40) / (120 - 40), 0.0, 1.0) \\ R_{\text{pause}} &= \text{clamp}((\text{Total_Durasi_Jeda}) / (\text{Total_Durasi_Rekaman}), 0.0, 1.0) \\ S_x &= \text{clamp}((x - x_{\text{min}}) / (x_{\text{max}} - x_{\text{min}}) \times 100, 0.0, 100.0) \end{aligned}$$

3.4 Engine Adaptif Progression CEFR (EWMA Algorithm)

Menggunakan *Exponentially Weighted Moving Average (EWMA)* agar kenaikan level siswa stabil dan tidak terfluktuasi secara drastis hanya karena 1 sesi latihan yang buruk:

$$S_{new} = 0.3 \times S_{final} + 0.7 \times S_{old}$$

- Rule Kenaikan Level:** Jika $\bar{S}_{new} \geq 80$ selama 3 sesi berturut-turut $\rightarrow$ Membuka modul CEFR berikutnya.
- Rule Intervensi:** Jika $\bar{S}_{new} < 55$ $\rightarrow$ Sistem mengaktifkan rekomendasi adaptif pada area terlemah.

3.5 Kontrak Data Output API JSON (Structured Response Contract)

Skema JSON standar yang dikembalikan oleh FastAPI backend untuk dikonsumsi oleh PWA Frontend dan Supabase:

```
{
  "session_id": "sess_2026_0924_001",
  "user_id": "usr_siswa_125",
  "mode": "ONLINE_FULL",
  "scores": {
    "pronunciation": 82.5, "fluency": 75.0, "intonation": 70.0,
    "grammar": 85.0, "vocabulary": 80.0, "final_score": 79.1
  },
  "metrics_detail": {
    "wpm": 88.5, "pause_ratio": 0.15, "phoneme_error_rate": 0.12,
    "type_token_ratio": 0.68, "cefr_level_detected": "B1"
  },
  "feedback_qualitative": {
    "strong_points": ["Grammar terstruktur dengan baik", "Kelancaran sesuai target"],
    "improvement_areas": ["Perhatikan pelafalan bunyi /o/ pada kata 'thorough'"],
    "corrections": [{
      "original": "I am study English since two years",
      "corrected": "I have been studying English for two years",
      "explanation": "Penggunaan tenses kurang tepat untuk durasi waktu."
    }]
  }
}
```

BAB 4: LANDASAN LITERATUR & VALIDASI AKADEMIS JURNAL

Seluruh metrik dan formulasi yang digunakan dalam TutorAI tervalidasi oleh literatur jurnal ilmiah internasional bereputasi tinggi (Scopus Q1/Q2, IEEE, Elsevier, Springer, Nature Portfolio):

Fokus Metrik	Referensi Jurnal Utama	Temuan Utama & Relevance pada TutorAI
Pronunciation & Accent	Derwing & Munro (2015) <i>Lang. Teach. / SSLA</i>	Membuktikan bahwa aksen lokal berbeda dengan unintelligibility. Evaluasi L2 wajib berfokus pada keterpahaman makna.
Acoustic PER & GOP	Witt & Young (2000) <i>Speech Communication</i>	Landasan algoritma Goodness of Pronunciation (GOP) dan Phoneme Error Rate (PER) untuk ASR.
Fluency & WPM	Kormos & Dénes (2004) <i>System (Elsevier)</i>	Memvalidasi WPM dan Pause Duration Ratio sebagai prediktor paling akurat untuk kelancaran L2.
Vocabulary & TTR	Lu (2012) <i>System (Elsevier)</i>	Memvalidasi penggunaan Type-Token Ratio (TTR) dan kerangka CEFR untuk mengukur variasi kata.
Grammar & AI Feedback	Zhang (2024) / Ding (2025) <i>BMC Psych. / Nature Port.</i>	Membuktikan bahwa AI real-time feedback menurunkan speaking anxiety dan meningkatkan self-regulation.
Multidimensional Scoring	Xi et al. / ETS (2008) <i>Language Testing (TOEFL)</i>	Landasan ETS TOEFL iBT dalam menyatukan 5 dimensi ke dalam weighted scoring system otomatis.

BAB 5: CHECKLIST IMPLEMENTASI & PENUTUP

Spesifikasi teknis ini telah dinyatakan lengkap dan siap diintegrasikan penuh ke dalam repositori kode TutorAI (Vercel PWA, FastAPI Backend Docker, dan ESP32-S3 PlatformIO).

- ✓ **Modul DSP & TinyML ESP32-S3:** Selesai diuji untuk VAD dan kalkulasi skor luring.
- ✓ **Modul FastAPI Backend:** Selesai mengintegrasikan pipeline Wav2Vec2, Qwen3-ASR, dan Gemma 4 GGUF.
- ✓ **Modul Database & PWA:** Selesai mengimplementasikan JSON Response Contract & Dashboard Guru.